

一、PAC基本概念

误差参数 ϵ ：预先设定的可行目标误差要求

概念 c ：样本空间到标记空间的映射

h ：假设出来的 c

h 与数据集 D 一致： h 在 D 上经验误差为0

- 不合(disagreement)

对于任意两个映射 $h_1, h_2 \in \mathcal{X} \rightarrow \mathcal{Y}$ 通过“不合”度量它们的差别

$$d(h_1, h_2) = P_{x \sim \mathcal{D}}(h_1(x) \neq h_2(x))$$

目标概念：把 x 都映射到了真实标记 y 上

概念类 C ：希望学得的目标概念集合

H ：某个学习算法所考虑的所有可能概念的集合

(与 C 通常不同)

H 包含了学习算法所有可能的输出假设

学习算法可分的&一致的： H 中存在目标概念 c

概率近似正确PAC：以较大概率学得满足 ϵ 的模型

PAC可辨识(PAC Identify)

学习算法若能以较大概率 $(1-\delta)$ 学得目标概念 c 的近似，称其能从假设空间 H 中PAC辨识概念类 C

对 $0 < \epsilon, \delta < 1$, 所有 $c \in C$ 和分布 \mathcal{D} , 若存在学习算法 \mathcal{L} , 其输出

假设 $h \in \mathcal{H}$ 满足

$$P(E(h) \leq \epsilon) \geq 1 - \delta,$$

则称学习算法 \mathcal{L} 能从假设空间 \mathcal{H} 中PAC辨识概念类 C .

PAC可学习(PAC Learnable)

令 m 表示从分布 \mathcal{D} 中独立同分布采样得到的样例数目, $0 < \epsilon, \delta < 1$,

对所有分布 \mathcal{D} , 若存在学习算法 \mathcal{L} 和多项式时间 $poly(\cdot, \cdot, \cdot, \cdot)$, 使得对于任何 $m \geq poly(1/\epsilon, 1/\delta, size(x), size(c))$, \mathcal{L} 能从假设空间 \mathcal{H} 中PAC辨识概念类 C , 则称概念类 C 对假设空间 \mathcal{H} 而言是PAC可学习的, 有时也简称概念类 C 是PAC可学习的。

- 若算法的运行时间同时满足是如下的多项式函数：

$$poly(1/\epsilon, 1/\delta, size(\mathbf{x}), size(c))$$

则概念类C是**高效**PAC可学习的，算法是概念类C的PAC学习算法

- 恰PAC可学习：假设空间H与概念类完全相同的情况

实际不可能

样本复杂度

假定学习算法 \mathcal{L} 处理每个样本的时间为常数，则 \mathcal{L} 的时间复杂度等价样本复杂度。于是，我们对算法时间复杂度的关心就转化到对样本复杂度的关心。

定义 样本复杂度(Sample Complexity)

满足PAC学习算法 \mathcal{L} 所需的 $m \geq poly(1/\epsilon, 1/\delta, size(\mathbf{x}), size(c))$ 中最小的 m ，称为学习算法 \mathcal{L} 的样本复杂度。

PAC意义

- 给出了一个抽象地刻画机器学习能力的框架，基于这个框架可以对很多重要问题进行理论探讨。
 - 研究某任务在什么样的条件下可学得较好的模型？
 - 某算法在什么样的条件下可进行有效的学习？
 - 需要多少训练样例才能获得较好的模型？
- 把对复杂算法的**时间复杂度**的分析转为对**样本复杂度**的分析

为什么不是希望精确地学到目标概念c呢？

机器学习过程受到很多因素的制约

- 训练集D只有有限的样例，因此通常会存在一些在D上“等效”的假设，学习算法对它们无法区别。
- 从分布采样得到的过程有一定的偶然性，即便对同样大小的不同训练集，学得结果也可能有所不同。

二、有限假设空间H

H越大，越可能包含目标概念，但找到越难

1、可分情形

目标概念c属于H时

- p 通常情形下, 由于训练集规模有限, 假设空间 \mathcal{H} 中可能存在不止一个与 D 一致的“等效”假设, 对这些假等效假设, 无法根据 D 来对它们的有优劣做进一步区分.

到底需要多少样例才能学得目标概念 c 的有效近似呢?

- p 训练集 D 的规模使得学习算法 \mathcal{L} 以概率 $1 - \delta$ 找到目标假设的 ϵ 近似, 则:

$$m \geq \frac{1}{\epsilon} (\ln |\mathcal{H}| + \ln \frac{1}{\delta}).$$

- 有限假设空间 \mathcal{H} 都是PAC可学习的, 所需的样例数目如上式所示, 输出假设 h 的泛化误差随样例数目的增多而收敛到0, 收敛速率为 $O(\frac{1}{m})$.

2、不可分情形

定义 **不可知PAC可学习(agnostic PAC Learnable)**

令 m 表示从分布 \mathcal{D} 中独立同分布采样得到的样例数目, $0 < \epsilon, \delta < 1$, 对所有分布 \mathcal{D} , 若存在学习算法 \mathcal{L} 和多项式时间 $\text{poly}(\cdot, \cdot, \cdot, \cdot)$, 使得对于任何 $m \geq \text{poly}(1/\epsilon, 1/\delta, \text{size}(\mathbf{x}), \text{size}(c))$, \mathcal{L} 能从假设空间 \mathcal{H} 中输出满足下式的假设 h :

$$P(E(h) - \min_{h' \in \mathcal{H}} E(h') \leq \epsilon) \geq 1 - \delta,$$

则称假设空间 \mathcal{H} 是不可知PAC可学习的.

- 若学习算法 \mathcal{L} 的运行时间也是多项式函数 $\text{poly}(1/\epsilon, 1/\delta, \text{size}(\mathbf{x}), \text{size}(c))$, 则
 - 称假设空间 \mathcal{H} 是高效不可知PAC可学习的;
 - 称学习算法 \mathcal{L} 为假设空间 \mathcal{H} 的不可知PAC学习算法;
 - 称满足上述要求最小的 m 为学习算法 \mathcal{L} 的样本复杂度.

三、VC维

1、增长函数

假设空间 \mathcal{H} 对 m 个示例能赋予标记的最大可能数

定义 12.6 对所有 $m \in \mathbb{N}$, 假设空间 \mathcal{H} 的增长函数 $\Pi_{\mathcal{H}}(m)$ 为

$$\Pi_{\mathcal{H}}(m) = \max_{\{\mathbf{x}_1, \dots, \mathbf{x}_m\} \subseteq \mathcal{X}} |\{(h(\mathbf{x}_1), \dots, h(\mathbf{x}_m)) \mid h \in \mathcal{H}\}|.$$

2分类最大就是 2^m

- 描述了 \mathcal{H} 的表示能力, 反映出 \mathcal{H} 的复杂度, 表示能力越强, 对学习任务适应能力就越强
- 增长函数可以估计经验误差和泛化误差的关系

定理 12.2 对假设空间 \mathcal{H} , $m \in \mathbb{N}$, $0 < \epsilon < 1$ 和任意 $h \in \mathcal{H}$ 有

$$P(|E(h) - \hat{E}(h)| > \epsilon) \leq 4\Pi_{\mathcal{H}}(2m) \exp\left(-\frac{m\epsilon^2}{8}\right).$$

对分dichotomy: 对二分类而言, H 中假设对 D 中示例赋予标记的每种结果都是对 D 的一种对分

打散shattering: H 能实现 D 上的所有对分, 称 D 被 H 打散

2、VC维

为什么引入VC维

实际学习任务中的无限假设空间, 研究可学习性需要度量假设空间复杂度, 最常用的是VC维

假设空间 \mathcal{H} 的VC维是能被 \mathcal{H} 打散的最大示例集的大小, 即

$$VC(\mathcal{H}) = \max\{m : \Pi_{\mathcal{H}}(m) = 2^m\}.$$

存在大小为 d 的示例集能被打散就行, 只需要构造出来

例子理解:

例 12.1 实数域中的区间 $[a, b]$: 令 \mathcal{H} 表示实数域中所有闭区间构成的集合 $\{h_{[a,b]} : a, b \in \mathbb{R}, a \leq b\}$, $\mathcal{X} = \mathbb{R}$. 对 $x \in \mathcal{X}$, 若 $x \in [a, b]$, 则 $h_{[a,b]}(x) = +1$, 否则 $h_{[a,b]}(x) = -1$. 令 $x_1 = 0.5$, $x_2 = 1.5$, 则假设空间 \mathcal{H} 中存在假设 $\{h_{[0,1]}, h_{[0,2]}, h_{[1,2]}, h_{[2,3]}\}$ 将 $\{x_1, x_2\}$ 打散, 所以假设空间 \mathcal{H} 的 VC 维至少为 2; 对任意大小为 3 的示例集 $\{x_3, x_4, x_5\}$, 不妨设 $x_3 < x_4 < x_5$, 则 \mathcal{H} 中不存在任何假设 $h_{[a,b]}$ 能实现对分结果 $\{(x_3, +), (x_4, -), (x_5, +)\}$. 于是, \mathcal{H} 的 VC 维为 2.

例 12.2 二维实平面上的线性划分: 令 \mathcal{H} 表示二维实平面上所有线性划分构成的集合, $\mathcal{X} = \mathbb{R}^2$. 由图 12.1 可知, 存在大小为 3 的示例集可被 \mathcal{H} 打散, 但不存在大小为 4 的示例集可被 \mathcal{H} 打散. 于是, 二维实平面上所有线性划分构成的假设空间 \mathcal{H} 的 VC 维为 3.



存在这样的集合, 其 $2^3 = 8$ 种对分均可被线性划分实现

(a) 示例集大小为 3



对任何集合, 其 $2^4 = 16$ 种对分中至少有一种不能被线性划分实现

(b) 示例集大小为 4

图 12.1 二维实平面上所有线性划分构成的假设空间的 VC 维为 3

四、Rademacher复杂度

与VC维不同的是，它在一定程度上考虑了数据分布

基于Rademacher复杂度的泛化误差界依赖于具体学习问题的数据分布，类似于为该问题“量身定制”的，因此它通常比基于VC维的泛化误差界要更紧一些

五、稳定性

VC维和Rademacher复杂度来分析泛化性能，得到的结果均与具体的学习算法无关

稳定性(stability)分析是这方面值得关注的方向。考察算法在输入(训练集)发生变化时，输出是否发生较大的变化

稳定性评价什么？

p 损失函数

$\ell(\mathcal{L}_D(x), y) : \mathcal{Y} \times \mathcal{Y} \mapsto \mathbb{R}^+$ 刻画假设 \mathcal{L}_D 的预测标记 $\mathcal{L}_D(x)$ 与真实标记 y 之间的差别，简记为 $\ell(\mathcal{L}_D, z)$ 。

- 泛化损失

$$\ell(\mathcal{L}, D) = \mathbb{E}_{x \in \mathcal{X}, z=(x,y)} [\ell(\mathcal{L}_D, z)].$$

- 经验损失

$$\hat{\ell}(\mathcal{L}, D) = \frac{1}{m} \sum_{i=1}^m \ell(\mathcal{L}_D, z_i).$$

- 留一(leave-one-out)损失：

$$\ell_{loo}(\mathcal{L}, D) = \frac{1}{m} \sum_{i=1}^m \ell(\mathcal{L}_{D \setminus i}, z_i).$$