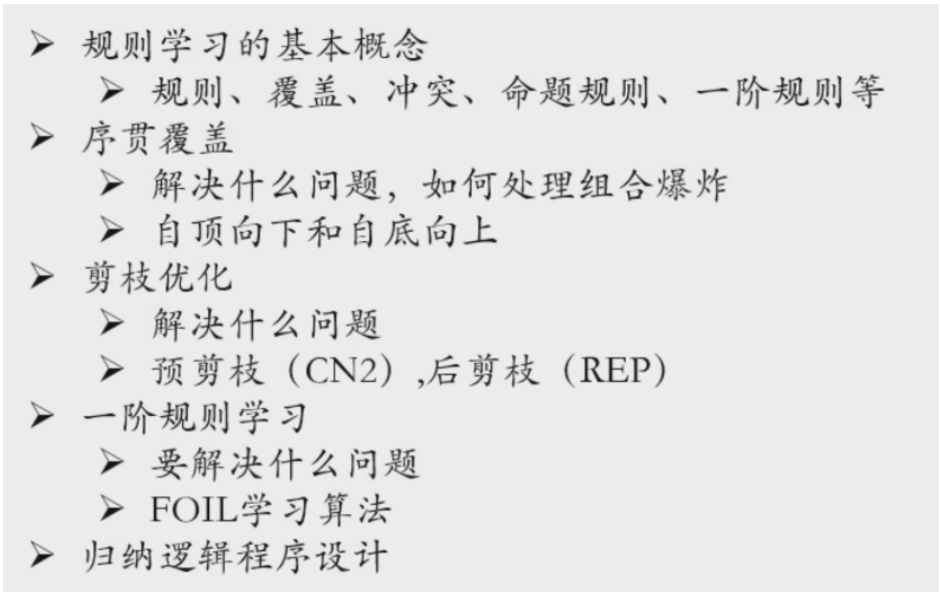

剪枝优化，对应算法，优缺点

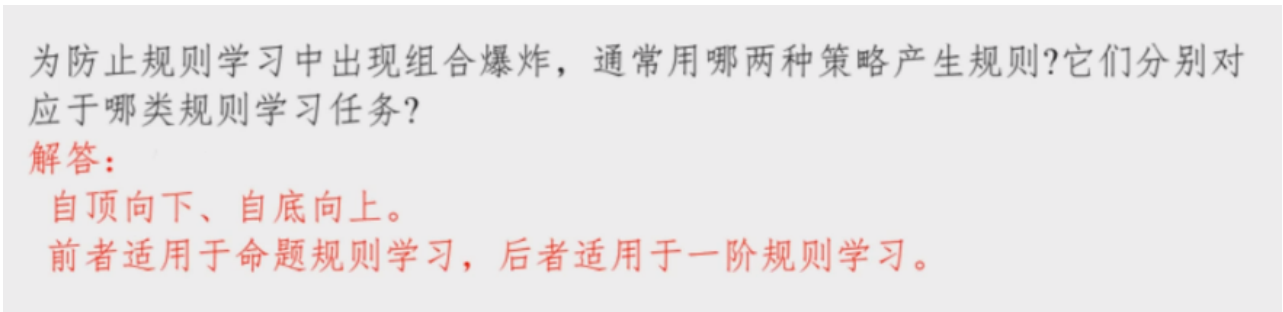

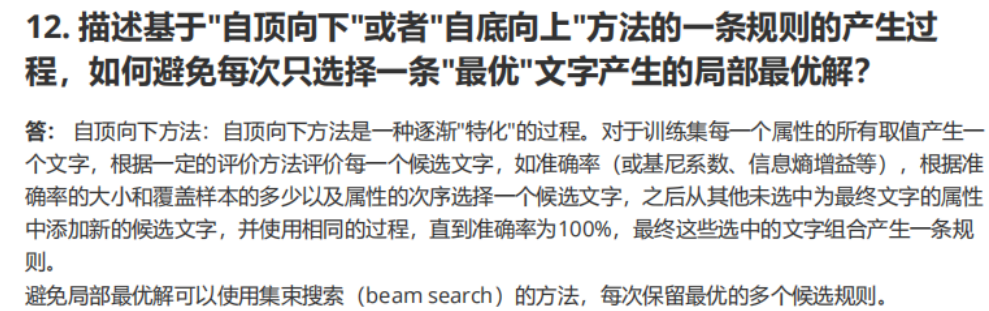

一、概念

规则：指语义明确、能描述数据分布所隐含的客观规律或领域概念、可写成"若……、则……"形式的逻辑规则

> 狭义的，省略了逻辑

规则学习：从训练数据中学习出一组能用于（泛化的）对未见示例进行判别的规则

优点：

- 可解释性更好
- 能更自然的在学习过程中引入领域知识
- 能基于逻辑规则进行推理，抽象描述能力强

覆盖：符合该规则的样本称为被规则覆盖（不等价）
冲突：同一个示例被判别结果不同的多条规则覆盖
冲突消解办法：

- 投票法
- 排序法：规则有优先级顺序
- 元规则法：根据领域知识事先设定的元规则（用于解决冲突，其实排序法也算一种元规则）

默认规则（缺省规则）：用来处理规则集合未覆盖到的样本

> 也是一种元规则

命题规则：由原子命题和逻辑连接词构成的简单陈述句
一阶规则：包含量词和逻辑变量

> 命题规则是一阶规则的特例

文字：原子公式及其否定

二、序贯覆盖

规则学习目标：产生最大覆盖的规则集
序贯覆盖=逐条归纳=分治策略：在训练集上每学到一条规则，就把该规则覆盖的样例去除
穷尽搜索会组合爆炸
一般的规则：空规则
特殊规则：直接以样例属性取值形成的规则

自顶向下（生成-测试）
从比较一般规则开始，逐渐添加新文字缩小覆盖范围，规则逐渐特化

- 容易产生泛化性能好的规则
- 对噪声的鲁棒性更强
- 适合命题规则学习

集束搜索：每轮保留最优的b个逻辑文字，在下一轮均用于构建候选集， 再把候选集中最优的b个留待再下一轮

自底向上（数据驱动）
从比较特殊规则开始，逐渐删除文字扩大覆盖范围，规则逐渐泛化

- 适合小样本
- 适合一阶规则学习（假设空间非常复杂的任务）

适用于多分类问题：当学习关于第c类的规则时，将所有属于类别c的样本作为正例，其他类别的样本作为反例

三、剪枝优化

贪心搜索需要剪枝缓解过拟合风险

通常是基于某种性能度量指标来评估增/删逻辑文字前后的规则性能，或增/删规则前后的规则集性能，从而判断是否要进行剪枝

预剪枝：CN2算法

用规则集预测必须显著优于直接基于训练集后验概率分布进行预测

似然率统计量LRS，越大说明越好，通常设置0.99才停止规则集生长

后剪枝：REP减错剪枝

在学得的规则集上穷举所有剪枝可能，选在验证集性能最好的，用验证集反复剪枝直到准确率无法提高

很有效，但复杂度太高

IREP：

每生成一条新规则即对其进行REP剪枝

RIPPER：

后处理优化过程

从全局考虑，缓解序贯覆盖贪心算法局部性

四、一阶规则学习

解决什么问题

命题规则难以处理对象间关系，而关系信息在很多任务中很重要

FOLL

优点：把命题规则学习过程通过变量替换等操作直接转化为一阶规则学习，因此比一般归纳逻辑程序设计技术更高效

缺点：大致看作命题规则学习与归纳逻辑程序设计之间的过渡，其自顶向下的规则生成过程不能支持函数和逻辑表达式嵌套，因此规则表达能力仍有不足