

## 一、优化问题

### 1、标准形式

### 2、最优解

例子

### 3、等价形式

#### 1.框约束

#### 2.换元

#### 3.松弛变量slack variables

#### 4.消除等式约束

#### 5.引入等式约束

#### 6.优化部分变量

#### 7.标准问题的上镜图问题形式

#### 8.隐式约束

## 二、凸优化

### 1、标准形式

例--转化为凸优化

### 2、凸优化问题局部最优一定全局最优

### 3、Optimality Criterion最优解判定

判定定理&证明:

无约束定理

例: 无约束二次规划

等号约束定理&证明

例：非负象限最小化问题

4、等价凸优化问题

5、拟凸优化

三、其他问题

1、线性规划

2、二次规划问题

3、几何规划Geometric Programming (GP)

4、广义不等约束Generalized

5、半正定SDP问题

## 一、优化问题

### 1、标准形式

min

不等约束要小于等于

$$\begin{aligned} \min \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & h_i(x) = 0, \quad i = 1, \dots, p \end{aligned}$$

- 定义域

$$\mathcal{D} = \bigcap_{i=0}^m \text{dom } f_i \cap \bigcap_{i=1}^p \text{dom } h_i$$

- 不起作用 (inactive) 约束:  $f_i(x) < 0$  时  $\leq 0$  不起作用
- 冗余约束: 去掉不改变可行集
- 可行性问题feasible

用于判断约束条件是否一致 (有解)

$$\begin{array}{ll}\text{find} & x \\ \text{subject to} & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & h_i(x) = 0, \quad i = 1, \dots, p.\end{array}$$

## 2、最优解

$$p^* = \inf \{f_0(x) \mid f_i(x) \leq 0, \quad i = 1, \dots, m, \quad h_i(x) = 0, \quad i = 1, \dots, p\}$$

- $p^*$ 为无穷：空集下确界是无穷
- $p^*$ 为负无穷：无下界unbounded blow

### $\epsilon$ -次优解

$$f_0(x) \leq p^* + \epsilon$$

### 局部最优

$$f_0(x) = \inf \{f_0(z) \mid f_i(z) \leq 0, \quad i = 1, \dots, m, \\ h_i(z) = 0, \quad i = 1, \dots, p, \quad \|z - x\|_2 \leq R\},$$

$$\begin{array}{ll}\min & f_0(z) \\ \text{s. t.} & f_i(z) \leq 0, \quad i = 1, \dots, m \\ & h_i(z) = 0, \quad i = 1, \dots, p \\ & \|z - x\|_2 \leq R\end{array}$$

### 例子

- $f_0(x) = 1/x$ :  $p^* = 0$ , 但最优值不可达。
- $f_0(x) = -\log x$ :  $p^* = -\infty$ , 所以该问题无下界。
- $f_0(x) = x \log x$ :  $p^* = -1/e$  在 (唯一的) 最优解  $x^* = 1/e$  处达到。

### 3、等价形式

从一个问题的解可以很容易得到另一个问题的

$$\begin{aligned} \min \quad & \tilde{f}(x) = \alpha_0 f_0(x) \\ \text{s.t.} \quad & \tilde{f}_i(x) = \alpha_i f_i(x) \leq 0, \quad i = 1, \dots, m \\ & \tilde{h}_i(x) = \beta_i h_i(x) = 0, \quad i = 1, \dots, p \end{aligned}$$

$$\blacksquare \alpha_i > 0, i = 0, \dots, m$$

$$\blacksquare \beta_i \neq 0, i = 1, \dots, p$$

### 1.框约束

改成上下界的样子

#### □ Box constraints

$$\begin{aligned} \min \quad & f_0(x) \\ \text{s.t.} \quad & l_i \leq x_i \leq u_i, \quad i = 1, \dots, n \end{aligned}$$

#### □ Reformulation

$$\begin{aligned} \min \quad & f_0(x) \\ \text{s.t.} \quad & l_i - x_i \leq 0, \quad i = 1, \dots, n \\ & x_i - u_i \leq 0, \quad i = 1, \dots, n \end{aligned}$$

### 2.换元

- ——映射
- 最优解相同，问题未必相同

**例 4.3 最小函数和最小范数平方问题。**作为一个简单的例子，考虑无约束的 Euclid 范数极小化问题

$$\text{minimize} \quad \|Ax - b\|_2, \quad (4.5)$$

其变量为  $x \in \mathbf{R}^n$ 。因为范数总是非负的，所以我们可以只求解问题

$$\text{minimize} \quad \|Ax - b\|_2^2 = (Ax - b)^T (Ax - b), \quad (4.6)$$

在这里，我们极小化 Euclid 范数的平方。问题 (4.5) 和问题 (4.6) 显然等价；最优解相同。但是，这两个问题是不相同。例如 问题 (4.5) 的目标函数在任意满足  $Ax - b = 0$  的  $x$  处都是不可微的，而问题 (4.6) 的目标函数对所有的  $x$  都是可微的（事实上，它是二次的）。

### 3.松弛变量slack variables

$f_i(x) \leq 0$  等价于存在一个  $s_i \geq 0$ ，满足  $f_i(x) + s_i = 0$

把每个不等约束，变成：一个等式约束+一个非负约束

$$\begin{array}{ll}\min & f_0(x) \\ \text{s. t.} & s_i \geq 0, \quad i = 1, \dots, m \\ & f_i(x) + s_i = 0, \quad i = 1, \dots, m \\ & h_i(x) = 0, \quad i = 1, \dots, p\end{array}$$

## 4.消除等式约束

$x=\varphi(z)$  替换，把等式约束参数化

$$\begin{array}{ll}\min & \tilde{f}_0(z) = f_0(\phi(z)) \\ \text{s. t.} & \tilde{f}_i(z) = f_i(\phi(z)) \leq 0, \quad i = 1, \dots, m\end{array}$$

## 消除线性等式约束

线性方程  $Ax = b$  的通解可以表示为  $Fz + x_0$

$z: R^k, k = n - \text{rank} A$

可以减少  $\text{rank} A$  个变量，且消除了线性等式约束

$$\begin{array}{ll}\min & f_0(Fz + x_0) \\ \text{s. t.} & f_i(Fz + x_0) \leq 0, \quad i = 1, \dots, m\end{array}$$

## 5.引入等式约束

$$\begin{array}{ll}\text{minimize} & f_0(A_0x + b_0) \\ \text{subject to} & f_i(A_ix + b_i) \leq 0, \quad i = 1, \dots, m \\ & h_i(x) = 0, \quad i = 1, \dots, p,\end{array}$$

- 引入  $y_i = A_i x + b_i$

$$\begin{array}{ll}\text{minimize} & f_0(y_0) \\ \text{subject to} & f_i(y_i) \leq 0, \quad i = 1, \dots, m \\ & y_i = A_ix + b_i, \quad i = 0, \dots, m \\ & h_i(x) = 0, \quad i = 1, \dots, p.\end{array}$$

该问题含有  $k_0 + \dots + k_m$  个新变量:

$$y_0 \in \mathbf{R}^{k_0}, \quad \dots, \quad y_m \in \mathbf{R}^{k_m},$$

及  $k_0 + \dots + k_m$  个新的等式约束:

$$y_0 = A_0 x + b_0, \quad \dots, \quad y_m = A_m x + b_m,$$

其目标函数与等式约束是独立的, 即它们各自包含不同的优化变量。

## 6. 优化部分变量

总可以通过先优化一部分变量, 再优化另一部分变量, 来优化函数

### □ Consider the problem

$$\begin{aligned} \min \quad & f_0(x_1, x_2) \\ \text{s. t.} \quad & f_i(x_1) \leq 0, \quad i = 1, \dots, m_1 \\ & \tilde{f}_i(x_2) \leq 0, \quad i = 1, \dots, m_2 \end{aligned}$$

### □ An Equivalent Problem

$$\begin{aligned} \min \quad & \tilde{f}_0(x_1) \\ \text{s. t.} \quad & f_i(x_1) \leq 0, \quad i = 1, \dots, m_1 \end{aligned}$$

■ where

$$\tilde{f}_0(x_1) = \inf \{f_0(x_1, z) \mid \tilde{f}_i(z) \leq 0, i = 1, \dots, m_2\}$$

不懂:

### Example

#### □ Minimize a Quadratic Function

$$\begin{aligned} \min \quad & x_1^\top P_{11} x_1 + 2x_1^\top P_{12} x_2 + x_2^\top P_{22} x_2 \\ \text{s. t.} \quad & f_i(x_1) \leq 0, \quad i = 1, \dots, m \end{aligned}$$

#### □ Minimize over $x_2$

$$\begin{aligned} \inf_{x_2} \quad & (x_1^\top P_{11} x_1 + 2x_1^\top P_{12} x_2 + x_2^\top P_{22} x_2) \\ & = x_1^\top (P_{11} - P_{12} P_{22}^{-1} P_{12}^\top) x_1 \end{aligned}$$


#### □ An Equivalent Problem

$$\begin{aligned} \min \quad & x_1^\top (P_{11} - P_{12} P_{22}^{-1} P_{12}^\top) x_1 \\ \text{s. t.} \quad & f_i(x_1) \leq 0, \quad i = 1, \dots, m \end{aligned}$$

## 7. 标准问题的上镜图问题形式

目标函数是t和x的线性函数

$$\begin{aligned} \text{minimize} \quad & t \\ \text{subject to} \quad & f_0(x) - t \leq 0 \\ & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & h_i(x) = 0, \quad i = 1, \dots, p, \end{aligned}$$



■ Find the point in the epigraph that minimizes  $t$

## 8.隐式约束

限制都被写进定义域

$$\min F(x)$$

$$\text{dom } F = \{x \in \text{dom } f_0 \mid f_i(x) \leq 0, i = 1, \dots, m, \\ h_i(x) = 0, i = 1, \dots, p\}$$

- 缺点：破坏可微性

## 二、凸优化

### 1、标准形式

理解：在凸集合上最小化一个凸函数

最大凹函数可以转化为最小凸函数

$$\begin{aligned} \min \quad & f_0(x) \\ \text{s. t.} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & a_i^\top x = b_i, \quad i = 1, \dots, p \end{aligned}$$

### 区别：三个条件

目标函数 $f$ 为凸

不等约束函数constraint: 凸

等号约束: 仿射

- 把条件变为凸集合

Feasible set of a convex optimization problem is convex

$$\bigcap_{i=0}^m \text{dom } f_i \cap \bigcap_{i=1}^m \{x | f_i(x) \leq 0\} \cap \bigcap_{i=1}^p \{x | a_i^\top x = b_i\}$$

✓ Minimize a convex function over a convex set

- 目标函数严格凸，则最优解至多一个

## 例--转化为凸优化

- 抽象成凸优化问题

$$\begin{aligned} \min \quad & f_0(x) = x_1^2 + x_2^2 \\ \text{s.t.} \quad & f_1(x) = x_1/(1+x_2^2) \leq 0 \\ & h_1(x) = (x_1+x_2)^2 = 0 \end{aligned}$$

- 等价变形，变凸优化问题

$$\begin{aligned} \min \quad & f_0(x) = x_1^2 + x_2^2 \\ \text{s.t.} \quad & f_1(x) = x_1 \leq 0 \\ & h_1(x) = x_1 + x_2 = 0 \end{aligned}$$

## 2、凸优化问题局部最优一定全局最优

证明：

- 1 先设出local是x， global是y
- 2 y与x有距离，因为y不是这个局部的最优解
- 3 构造z为xy两点结构，能用上琴声
- 4 最后推出z比x更优，与x局部最优矛盾



设  $x$  是凸优化问题的局部最优解, 即  $x$  是可行的并且对于某些  $R > 0$ , 有

$$f_0(x) = \inf\{f_0(z) \mid z \text{ 可行}, \|z - x\|_2 \leq R\}, \quad (4.19)$$

现在假设  $x$  不是全局最优解, 即存在一个可行的  $y$  使得  $f_0(y) < f_0(x)$ 。显然  $\|y - x\|_2 > R$ , 因为否则的话有  $f_0(x) \leq f_0(y)$ 。考虑由

$$z = (1 - \theta)x + \theta y, \quad \theta = \frac{R}{2\|y - x\|_2}$$

给出的点  $z$ , 我们有  $\|z - x\|_2 = R/2 < R$ 。根据可行集的凸性,  $z$  是可行的。根据  $f_0$  的凸性, 我们有

$$f_0(z) \leq (1 - \theta)f_0(x) + \theta f_0(y) < f_0(x),$$

这与式(4.19) 矛盾。因此不存在满足  $f_0(y) < f_0(x)$  的可行解  $y$ , 即  $x$  是全局最优解。

### 3、Optimality Criterion最优解判定

#### 判定定理&证明:

- 假设  $f$  differentiable 可微,  $X$  为 feasible set 可行解集合

设凸优化问题的目标函数  $f_0$  是可微的, 对于所有的  $x, y \in \text{dom } f_0$  有

$$f_0(y) \geq f_0(x) + \nabla f_0(x)^T(y - x) \quad (4.20)$$

(参见 §3.1.3)。令  $X$  表示其可行集, 即

$$X = \{x \mid f_i(x) \leq 0, i = 1, \dots, m, h_i(x) = 0, i = 1, \dots, p\}.$$

那么,  $x$  是最优解, 当且仅当  $x \in X$  且

$$\nabla f_0(x)^T(y - x) \geq 0, \forall y \in X. \quad (4.21)$$

这个最优性准则可以从几何上进行理解: 如果  $\nabla f_0(x) \neq 0$ , 那么意味着  $-\nabla f_0(x)$  在  $x$  处定义了可行集的一个支撑超平面 (参见图4.2)。

☐ 充分条件 sufficient condition

- 1 代入即可, 利用梯度性质和一阶条件

☐ 必要条件 necessary condition

- 1 反设  $x$  最优但不满足不等式
- 2 两点构造  $z$ , 求导可出现目标式子
- 3 与  $x$  最优矛盾

- Suppose  $x$  is optimal but

$$\exists y \in X, \nabla f_0(x)^\top (y - x) < 0$$

- Define  $z(t) = ty + (1 - t)x, t \in [0, 1]$

$$f_0(z(0)) = f_0(x), \quad \left. \frac{d}{dt} f_0(z(t)) \right|_{t=0} = \nabla f_0(x)^\top (y - x) < 0$$

- So, for small positive  $t$ ,  $f_0(z(t)) < f_0(x)$

## 无约束定理

无约束，才行

□  $x$  is optimal if and only if  $\nabla f_0(x) = 0$

- Consider  $y = x - t \nabla f_0(x)$  and  $t > 0$

- When  $t$  is small,  $y$  is feasible

$$\nabla f_0(x)^\top (y - x) = -t \|\nabla f_0(x)\|_2^2 \geq 0 \Leftrightarrow \nabla f_0(x) = 0$$

## 例：无约束二次规划

- 1 讨论线性方程组的解3种可能性
- 2 首先通过 $q$ 属于 $\mathcal{R}(P)$ 分成有无解两种情况
- 3 1、无解： $p$ 不属于 $q$ 列向量的空间：向下优化会达到负无穷
- 4 2、唯一解： $p$ 正定矩阵，可逆，直接求解、
- 5 3、无穷解： $p$ 奇异，有无穷解，用伪逆得到一个解
- 6 //与消掉等号约束部分类似

例 4.5 无约束二次规划。考虑极小化二次函数

$$f_0(x) = (1/2)x^T P x + q^T x + r,$$

其中,  $P \in \mathbf{S}_+^n$  (保证了  $f_0$  为凸函数)。  $x$  为  $f_0$  的最小解的充要条件是:

$$\nabla f_0(x) = P x + q = 0.$$

根据这个(线性)方程无解、有唯一解或有多解的不同, 有几种可能的情况

- 如果  $q \notin \mathcal{R}(P)$ , 则无解。此类情况  $f_0$  无下界。
- 如果  $P \succ 0$  (意味着  $f_0$  严格凸), 则存在唯一的最小解  $x^* = -P^{-1}q$ 。
- 如果  $P$  奇异但  $q \in \mathcal{R}(P)$ , 则最优解集合为(仿射)集合  $X_{\text{opt}} = -P^\dagger q + \mathcal{N}(P)$ , 其中  $P^\dagger$  表示  $P$  的伪逆(参见 §A.5.4)。

## 等号约束定理&证明

### □ Consider the Problem

$$\begin{array}{ll}\min & f_0(x) \\ \text{s.t.} & Ax = b\end{array}$$

### □ $x$ is optimal if and only if

$$\nabla f_0(x)^\top (y - x) \geq 0, \forall Ay = b$$

### □ 等价形式

Lagrange Multiplier  
Optimality Condition

$$\begin{array}{l}Ax = b \\ \nabla f_0(x) + A^\top v = 0\end{array}$$

### □ 证明

$$\left. \begin{array}{l}\nabla f_0(x)^\top (y - x) \geq 0, \forall Ay = b \\ \{y | Ay = b\} = \{x + v | v \in \mathcal{N}(A)\}\end{array} \right\}$$

$$\Leftrightarrow \nabla f_0(x)^\top v \geq 0, \forall v \in \mathcal{N}(A)$$

$$\Leftrightarrow \nabla f_0(x)^\top v = 0, \forall v \in \mathcal{N}(A)$$

$$\Leftrightarrow \nabla f_0(x) \perp \mathcal{N}(A) \Leftrightarrow \nabla f_0(x) \in \mathcal{N}(A)^\perp = \mathcal{R}(A^\top)$$

$$\Leftrightarrow \exists v \in \mathbf{R}^p, \nabla f_0(x) + A^\top v = 0$$

## 例：非负象限最小化问题

作为另一个例子，我们考虑问题

$$\begin{array}{ll}\text{minimize} & f_0(x) \\ \text{subject to} & x \succeq 0,\end{array}$$

这里唯一的不等式约束是变量的非负约束。

于是，最优性条件 (4.21) 为

$$x \succeq 0, \quad \nabla f_0(x)^\top (y - x) \geq 0, \quad \forall y \succeq 0.$$

$\nabla f_0(x)^\top y$  是  $y$  的线性函数并且在  $y \succeq 0$  上无下界，除非我们有  $\nabla f_0(x) \succeq 0$ 。于是，这个条件简化为  $-\nabla f_0(x)^\top x \geq 0$ 。但是  $x \succeq 0$  且  $\nabla f_0(x) \succeq 0$ ，所以必须有  $\nabla f_0(x)^\top x = 0$ ，即

$$\sum_{i=1}^n (\nabla f_0(x))_i x_i = 0.$$

这里求和中的每一项都是两个非负数的乘积，因此可知每一项都必须为零，即对于  $i = 1, \dots, n$ ，有  $(\nabla f_0(x))_i x_i = 0$ 。

因此，最优性条件可以表示为

$$x \succeq 0, \quad \nabla f_0(x) \succeq 0, \quad x_i (\nabla f_0(x))_i = 0, \quad i = 1, \dots, n.$$

最后一个条件称为互补性，因为它意味着向量  $x$  和  $\nabla f_0(x)$  的稀疏模式（即非零分量对应的索引集合）是互补的（即交集为空）。我们将在第 5 章中再次深入地讨论互补条件。

## 4、等价凸优化问题

有用的保凸

### 引入等式约束

1  $f(Ax+b)$  变为  $f(y)$  和  $y=Ax+b$

### 松弛变量

- Introduce new constraint  $f_i(x) + s_i = 0$  and requiring that  $f_i$  is affine
- Introduce slack variables for linear inequalities preserves convexity of a problem

### 局部变量最小化

- It preserves convexity.  $f_0(x_1, x_2)$  needs to be jointly convex in  $x_1$  and  $x_2$

### 上图问题形式

## 5、拟凸优化

- 局部最优非全局最优

## 三、其他问题

---

### 1、线性规划

## □ Linear Program (LP)

$$\begin{array}{ll}\min & c^\top x + d \\ \text{s. t.} & Gx \leq h \\ & Ax = b\end{array}$$

- $G \in \mathbf{R}^{m \times n}$  and  $A \in \mathbf{R}^{p \times n}$
- It is common to omit the constant  $d$
- Maximization problem with affine objective and constraint functions is also an LP
- The feasible set of LP is a polyhedron  $\mathcal{P}$

### 不等形式

无等号约束

$$\begin{array}{ll}\min & c^\top x \\ \text{s. t.} & Ax \leq b\end{array}$$

### 标准形式

唯一不等式是  $x \geq 0$

$$\begin{array}{ll}\min & c^\top x \\ \text{s. t.} & Ax = b \\ & x \geq 0\end{array}$$

### 转化为标准形式

1 引入 slack 变量  $s$

$$\begin{array}{ll}\min & c^\top x + d \\ \text{s. t.} & Gx \leq h \\ & Ax = b\end{array} \quad \Rightarrow \quad \begin{array}{ll}\min & c^\top x + d \\ \text{s. t.} & Gx + s = h \\ & Ax = b \\ & s \geq 0\end{array}$$

1 decompose  $x$  变换 (干啥呢)

## □ Decompose $x$

$$x = x^+ - x^-, \quad x^+, x^- \geq 0$$

## □ Standard Form LP

$$\begin{array}{ll} \min & c^\top x + d \\ \text{s.t.} & Gx + s = h \\ & Ax = b \\ & s \geq 0 \end{array} \quad \Rightarrow \quad \begin{array}{ll} \min & c^\top x^+ - c^\top x^- + d \\ \text{s.t.} & Gx^+ - Gx^- + s = h \\ & Ax^+ - Ax^- = b \\ & x^+ \geq 0, x^- \geq 0, s \geq 0 \end{array}$$

## 2、二次规划问题

### □ Quadratic Program (QP)

$$\begin{array}{ll} \min & (1/2)x^\top Px + q^\top x + r \\ \text{s.t.} & Gx \leq h \\ & Ax = b \end{array}$$

- $P \in \mathbf{S}_+^n, G \in \mathbf{R}^{m \times n}$  and  $A \in \mathbf{R}^{p \times n}$
- The objective function is (convex) quadratic
- The constraint functions are affine
- When  $P = 0$ , QP becomes LP

## 变二次约束

椭圆与超平面

### □ Quadratically Constrained Quadratic Program (QCQP)

$$\begin{array}{ll} \min & (1/2)x^\top P_0 x + q_0^\top x + r_0 \\ \text{s.t.} & (1/2)x^\top P_i x + q_i^\top x + r_i \leq 0, \quad i = 1, \dots, m \\ & Ax = b \end{array}$$

- $P_i \in \mathbf{S}_+^n, i = 0, \dots, m$
- The inequality constraint functions are (convex) quadratic
- The feasible set is the intersection of ellipsoids (when  $P_i > 0$ ) and an affine set
- Include QP as a special case

## 二阶锥优化问题

不等约束是二阶锥SOC

### □ Second-order Cone Program (SOCP)

$$\begin{aligned} \min \quad & f^\top x \\ \text{s.t.} \quad & \|A_i x + b_i\|_2 \leq c_i^\top x + d_i, \quad i = 1, \dots, m \\ & Fx = g \end{aligned}$$

$$\blacksquare A_i \in \mathbf{R}^{n_i \times n}, F \in \mathbf{R}^{p \times n}$$

- Second-order Cone (SOC) constraint:  
 $\|Ax + b\|_2 \leq c^\top x + d$  where  $A \in \mathbf{R}^{k \times n}$ , is same as requiring  $(Ax + b, c^\top x + d) \in \text{SOC}$  in  $\mathbf{R}^{k+1}$

$$\begin{aligned} \text{SOC} &= \{(x, t) \in \mathbf{R}^{k+1} \mid \|x\|_2 \leq t\} \\ &= \left\{ \begin{bmatrix} x \\ t \end{bmatrix} \mid \begin{bmatrix} x \\ t \end{bmatrix}^\top \begin{bmatrix} I & 0 \\ 0 & -1 \end{bmatrix} \begin{bmatrix} x \\ t \end{bmatrix} \leq 0, t \geq 0 \right\} \end{aligned}$$

## 3、几何规划Geometric Programming (GP)

定义域,  $c$ 都 $>0$

- 单项式, 多项式

$$f(x) = cx_1^{a_1} x_2^{a_2} \dots x_n^{a_n}$$

加减乘除运算闭合

但多项式除运算未必闭合

$$f(x) = \sum_{k=1}^K c_k x_1^{a_{1k}} x_2^{a_{2k}} \dots x_n^{a_{nk}}$$

### 转化为几何规划

$$\begin{aligned} \min \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 1, \quad i = 1, \dots, m \\ & h_i(x) = 1, \quad i = 1, \dots, p \end{aligned}$$

$f$ 多项式,  $h$ 单项式, 定义域正

总能化成 $\leq 1, < 1$ 形式

最大要变成最小

隐含了不等约束 $x > 0$

### 例子

$$\begin{aligned} \max \quad & x/y \\ \text{s.t.} \quad & 2 \leq x \leq 3 \\ & x^2 + 3y/z \leq \sqrt{y} \\ & x/y = z^2 \end{aligned} \quad \Leftrightarrow \quad \begin{aligned} \min \quad & x^{-1}y \\ \text{s.t.} \quad & 2x^{-1} \leq 1, (1/3)x \leq 1 \\ & x^2 y^{-1/2} + y^{1/2} z^{-1} \leq 1 \\ & xy^{-1}z^{-2} = 1 \end{aligned}$$

## 凸化几何优化

- 先e幂

1 用e的幂代替x，可以合并连乘

### ■ $f$ is the monomial function

$$f(x) = cx_1^{a_1} x_2^{a_2} \dots x_n^{a_n}, \quad x_i = e^{y_i}$$

$$\begin{aligned} f(x) &= f(e^{y_1}, \dots, e^{y_n}) = c(e^{y_1})^{a_1} \dots (e^{y_n})^{a_n} \\ &= e^{a_1 y_1 + \dots + a_n y_n + \log c} = e^{a^\top y + b} \end{aligned}$$

### ■ $f$ is the posynomial function

$$f(x) = \sum_{k=1}^K c_k x_1^{a_{1k}} x_2^{a_{2k}} \dots x_n^{a_{nk}}$$

$$f(x) = \sum_{k=1}^K e^{a_k^\top y + b_k}$$

- 再取log

1 取log可以把约束变换成凸形式

### □ New Form

$$\begin{aligned} \min \quad & \sum_{k=1}^{K_0} e^{a_{0k}^\top y + b_{0k}} \\ \text{s.t.} \quad & \sum_{k=1}^{K_i} e^{a_{ik}^\top y + b_{ik}} \leq 1, \quad i = 1, \dots, m \\ & e^{g_i^\top y + h_i} = 1, \quad i = 1, \dots, p \end{aligned}$$

### □ Taking the Logarithm

$$\begin{aligned} \min \quad & \tilde{f}_0(y) = \log \left( \sum_{k=1}^{K_0} e^{a_{0k}^\top y + b_{0k}} \right) \\ \text{s.t.} \quad & \tilde{f}_i(y) = \log \left( \sum_{k=1}^{K_i} e^{a_{ik}^\top y + b_{ik}} \right) \leq 0, \quad i = 1, \dots, m \\ & \tilde{h}_i(y) = g_i^\top y + h_i = 0, \quad i = 1, \dots, p \end{aligned}$$

## 4、广义不等约束Generalized



$$\begin{array}{ll} \min & f_0(x) \\ \text{s. t.} & f_i(x) \preceq_{K_i} 0, \quad i = 1, \dots, m \\ & Ax = b \end{array}$$

- $f_0: \mathbf{R}^n \rightarrow \mathbf{R}$  is convex;
- $K_i \subseteq \mathbf{R}^{k_i}$  are proper cones
- $f_i: \mathbf{R}^n \rightarrow \mathbf{R}^{k_i}$  is  $K_i$ -convex w.r.t. proper cone  $K_i \subseteq \mathbf{R}^{k_i}$

## 锥形式

仿射，线性

$$\begin{array}{ll} \min & c^\top x \\ \text{s. t.} & Fx + g \preceq_K 0 \\ & Ax = b \end{array}$$

## 标准形式

$$\begin{array}{ll} \min & c^\top x \\ \text{s. t.} & x \succeq_K 0 \\ & Ax = b \end{array}$$

## 不等形式

$$\begin{array}{ll} \min & c^\top x \\ \text{s. t.} & Fx + g \preceq_K 0 \end{array}$$

## 5、半正定SDP问题

锥形式广义不等约束

$$\begin{array}{ll} \min & c^\top x \\ \text{s. t.} & x_1 F_1 + \dots + x_n F_n + G \preceq 0 \\ & Ax = b \end{array}$$

## 标准形式

$$\begin{array}{ll}
 \min & \text{tr}(CX) \\
 \text{s. t.} & \text{tr}(A_i X) = b_i, \quad i = 1, \dots, p \\
 & X \succcurlyeq 0
 \end{array}$$

**不等形式**

$$\begin{array}{ll}
 \min & c^\top x \\
 \text{s. t.} & x_1 A_1 + \dots + x_n A_n \preceq B
 \end{array}$$