

隐藏状态：想得到的属性
从观测值推测出隐藏状态序列

一、模型简介

- 可用于序列标注问题的统计学模型，描述了由隐马尔可夫链随机生成观测序列的过程，属于生成模型。
- 是关于时序的概率模型，描述由一个隐藏的马尔可夫链随机生成不可观测的状态随机序列，再由各个状态生成一个观测值，从而做种产生观测序列的过程。

关键概念

- 状态序列：隐藏的马尔可夫链随机生成的状态的序列。
- 观测序列：每个状态生成一个观测，而由此产生的观测的随机序列称作观测序列。
- 序列的每一个位置又可以看作是一个时刻。

状态序列：文字（状态空间）

观测序列：拼音

- 状态集合为 $\mathbb{Q} = \{q_1, q_2, \dots, q_Q\}$ ，观测值集合为 $\mathbb{V} = \{v_1, v_2, \dots, v_V\}$
 - Q 和 V 分别表示状态数量和观测值数量
- 设 $\mathbf{I} = (i_1, i_2, \dots, i_T)$ 是长度为 T 的状态序列， $\mathbf{O} = (o_1, o_2, \dots, o_T)$ 是对应的观测序列
 - $i_t \in \{1, \dots, Q\}$ 是一个随机变量，代表一个可能的状态值 q_{i_t}
 - $o_t \in \{1, \dots, V\}$ 是一个随机变量，代表一个可能的观测值 v_{o_t}

$$P(i_1, i_2, \dots, i_T, o_1, o_2, \dots, o_T), \quad t = 1, 2, \dots, T$$

二、模型表示

隐马尔可夫模型由初始状态概率 π 、状态转移矩阵 \mathbf{A} 、以及观测概率矩阵 \mathbf{B} 决定。一个隐马尔可夫模型可用三元符号表示： $\lambda = (\mathbf{A}, \mathbf{B}, \pi)$

- 初始状态概率 π 和状态转移矩阵 \mathbf{A} 确定了隐藏的马尔可夫链，生成了不可观测的状态序列；
- 观测概率矩阵 \mathbf{B} 确定了如何从状态生成观测值，与状态序列一起确定了如何产生观测序列。

1、齐次性假设--状态转移矩阵

隐藏马链任意时刻的状态只依赖于前一时刻的状态，与其他时刻状态和观测无关，与时刻 t 也无关

$$P(i_t|i_1, o_1, \dots, i_{t-1}, o_{t-1}) = P(i_t|i_{t-1}), \quad t = 1, 2, \dots, T$$

- a_{ij} 表示从 q_i 状态转移到 q_j 状态的概率

其中 $a_{i,j} = P(i_{t+1} = q_j | i_t = q_i)$, 表示在 t 时刻处于状态 q_i 的条件下, 在 $t + 1$ 时刻转移到 q_j 的概率

$$\mathbf{A} = \begin{bmatrix} a_{1,1} & a_{1,2} & \dots & a_{1,Q} \\ a_{2,1} & a_{2,2} & \dots & a_{2,Q} \\ \vdots & \vdots & \ddots & \vdots \\ a_{Q,1} & a_{Q,2} & \dots & a_{Q,Q} \end{bmatrix}$$

2、观测独立性假设--观测概率矩阵

- 任意时刻观测值只和当前时刻马链状态有关, 和其他观测和状态无关

$$P(o_t|i_1, o_1, \dots, i_{t-1}, o_{t-1}, i_t) = P(o_t|i_t), \quad t = 1, 2, \dots, T$$

- $b_j(k)$ 表示从 q_j 状态生成观测值 v_k 的概率

其中 $b_j(k) = P(o_t = v_k | i_t = q_j)$, 表示 t 时刻处于状态 q_j 的条件下生成观测值 v_k 的概率

$$\mathbf{B} = \begin{bmatrix} b_1(1) & b_1(2) & \dots & b_1(V) \\ b_2(1) & b_2(2) & \dots & b_2(V) \\ \vdots & \vdots & \ddots & \vdots \\ b_Q(1) & b_Q(2) & \dots & b_Q(V) \end{bmatrix}$$

3、状态初始化\pi

π 为初始的状态概率: $\pi = (\pi_1, \pi_2, \dots, \pi_Q)$

- $\pi_i = P(i_1 = q_i)$ 表示开始时刻 $t = 1$ 时处于状态 q_i 的概率
- $\sum_{i=1}^Q \pi_i = 1$

三、运算

1、生成观测序列

- 输入：隐马尔可夫模型 $\lambda = (\mathbf{A}, \mathbf{B}, \pi)$ 和观测序列长度 T
- 输出：观测序列 $\mathbf{O} = (o_1, o_2, \dots, o_T)$
- 算法步骤：
 - 按照初始状态分布 π 产生状态 i_1
 - 令 $t = 1$ ，开始迭代。迭代条件： $t \leq T$ 。迭代步骤为：
 - 按照状态 i_t 的观测概率分布 $b_j(k)$ 生成观测值 o_t
 - 按照状态 i_t 的状态转移分布 $a_{i,j}$ 产生状态 i_{t+1}
 - 令 $t = t + 1$

2、基本问题

1、学习问题（极大似然）

- 已知序列，求未知的参数使序列可能性最大
 - 如果训练数据有观测数据和对应的状态序列，则可监督学习来学习隐马
- 搜狗新闻语料，python包转为拼音，得到对应关系
- 如果训练数据仅有观测序列，无监督学习

2、概率计算问题

输入法项目用不到

给定模型参数，求某一观测序列产生的概率

3、预测解码问题

给定模型参数，求某一观测序列对应的最大可能状态序列

- 学习问题
 - 已知观测序列 $\mathbf{O} = (o_1, o_2, \dots, o_T)$, 估计模型 $\lambda = (\mathbf{A}, \mathbf{B}, \pi)$ 的参数, 使得该模型下观测序列的概率 $P(\mathbf{O}; \lambda)$ 最大。
- 概率计算问题
 - 给定模型 $\lambda = (\mathbf{A}, \mathbf{B}, \pi)$ 和观测序列 $\mathbf{O} = (o_1, o_2, \dots, o_T)$, 计算观测序列 \mathbf{O} 出现的概率 $P(\mathbf{O}; \lambda)$
- 预测问题 (解码问题)
 - 已知模型 $\lambda = (\mathbf{A}, \mathbf{B}, \pi)$ 和观测序列 $\mathbf{O} = (o_1, o_2, \dots, o_T)$, 求该观测序列对应的最可能的状态序列 $\mathbf{I} = (i_1, i_2, \dots, i_T)$

四、例题-学习问题-监督学习

- 用频率估计概率得到三个重要参数
- 假设数据集为 $\mathbb{D} = \{(\mathbf{O}_1, \mathbf{I}_1), (\mathbf{O}_2, \mathbf{I}_2), \dots, (\mathbf{O}_N, \mathbf{I}_N)\}$, 其中:
 - $\mathbf{O}_1, \dots, \mathbf{O}_N$ 为 N 个观测序列; $\mathbf{I}_1, \dots, \mathbf{I}_N$ 为对应的 N 个观测序列。
 - 序列 \mathbf{O}_k , \mathbf{O}_k 的长度为 T_k 。
- 估计转移概率 $a_{i,j}$
 - 设样本中前一时刻处于状态 q_i 、且后一时刻处于 q_j 的频数为 $A_{i,j}$, 则转移概率 $a_{i,j}$ 的估计是:

$$a_{i,j} = \frac{A_{i,j}}{\sum_{u=1}^Q A_{i,u}}, \quad i = 1, 2, \dots, Q; \quad j = 1, 2, \dots, Q$$

- 估计观测概率 $b_j(k)$
 - 设样本中状态为 q_j 且其对应观测值为 v_k 的频数为 $B_{j,k}$, 则状态为 q_j 并且观测值为 v_k 的概率 $b_j(k)$ 的估计为:

$$b_j(k) = \frac{B_{j,k}}{\sum_{v=1}^V B_{j,v}}, \quad j = 1, 2, \dots, Q; \quad k = 1, 2, \dots, V$$

- 估计初始状态概率 π_i
 - 设样本中初始时刻 ($t = 1$) 处于状态 q_i 的频数为 C_i , 则初始状态概率 π_i 的估计为:

$$\pi_i = \frac{C_i}{\sum_{j=1}^Q C_j}, \quad i = 1, 2, \dots, Q;$$

$$\operatorname{argmax}_{i_1, i_2, \dots, i_T} P(i_1, i_2, \dots, i_T, o_1, o_2, \dots, o_T) = \operatorname{argmax}_{i_1, i_2, \dots, i_T} \pi_{i_1} \sum_{t=1}^T a_{i_t, i_{t+1}} b_{i_t}(o_t)$$

计算复杂度: $O(T \times Q^T)$

- 下山：2拓展到q，动态规划降低复杂度

五、预测问题---维特比算法

- 根据动态规划原理，最优路径具有这样的特性：如果最优路径在时刻 t 通过结点 i_t^* ，则这一路径从结点 i_t^* 到终点 i_T^* 的部分路径，对于从 i_t^* 到 i_T^* 的所有可能路径来说，也必须是最优的。



- 只需要从时刻 $t = 1$ 开始，递推地计算从时刻 1 到时刻 t 且时刻 t 状态为 i ($i = 1, 2, \dots, Q$) 的各条部分路径的最大概率（以及取最大概率的状态）。于是在时刻 $t = T$ 的最大概率即为最优路径的概率 P^* ，最优路径的终结点 i_T^* 也同时得到。
- 之后为了找出最优路径的各个结点，从终结点 i_T^* 开始，由后向前逐步求得结点 i_{T-1}^*, \dots, i_1^* ，得到最优路径 $\mathbf{I}^* = (i_1^*, i_2^*, \dots, i_T^*)$ 。

17

符号定义

- t 时刻状态为 q_i 的所有可能的路径 (i_1, i_2, \dots, i_t) 中概率最大值为：

$$\delta_t(i) = \max_{i_1, \dots, i_{t-1}} P(i_1, \dots, i_{t-1}, i_t = q_i, o_1, \dots, o_t), \quad i = 1, 2, \dots, Q$$

- 则根据定义，得到变量 δ 的递推公式

$$\delta_t(i) = \max_{i_1, \dots, i_{t-1}} P(i_1, \dots, i_{t-1}, i_t = q_i, o_1, \dots, o_t) = \max_{1 \leq j \leq Q} \delta_{t-1}(j) \times a_{j,i} \times b_i(o_t) \\ i = 1, 2, \dots, Q; \quad t = 2, \dots, T$$

- t 时刻状态为 q_i 的所有单个路径中概率最大的路径的第 $t-1$ 个结点为：

$$\Psi_t(i) = \operatorname{argmax}_{1 \leq j \leq Q} \delta_{t-1}(j) a_{j,i}, \quad i = 1, 2, \dots, Q$$

18

- 输入：隐马尔可夫模型 $\lambda = (\mathbf{A}, \mathbf{B}, \pi)$ ，观测序列 $\mathbf{O} = (o_1, o_2, \dots, o_T)$

- 输出：最优的状态路径 $\mathbf{I}^* = (i_1^*, i_2^*, \dots, i_T^*)$

算法流程：

- 初始化： $\delta_1(i) = \pi_i b_i(o_1), \Psi_1(i) = 0, \quad i = 1, 2, \dots, Q$
- 递推： $\delta_t(i) = \max_{1 \leq j \leq Q} \delta_{t-1}(j) \times a_{j,i} \times b_i(o_t)$
 $\Psi_t(i) = \operatorname{argmax}_{1 \leq j \leq Q} \delta_{t-1}(j) a_{j,i} \quad i = 1, 2, \dots, Q; \quad t = 2, \dots, T$
- 终止： $P^* = \max_{1 \leq i \leq Q} \delta_T(i), \quad i_T^* = \operatorname{argmax}_{1 \leq i \leq Q} \delta_T(i) a_{i,i}$
- 最优路径回溯： $i_t^* = \Psi_{t+1}(i_{t+1}^*), \quad t = T-1, \dots, 1$
- 获得最优路径 $\mathbf{I}^* = (i_1^*, i_2^*, \dots, i_T^*)$ 。

做拼音时，要存top 10序列和相应的概率